


서론


- MAP3K5 단백질의 IC50 예측을 위해 다양한 단백질에 대한 IC50 데이터를 대규모로 수집, 그중 MAP3K5와 유사한 단백질을 PSI-BLAST로 선별함.
- 다양한 화합물 표현법으로 앙상블 모델을 구축하여 화합물의 IC50 활성을 예측함.

훈련 데이터 전략



- PubChem, BindingDB, CAS, ChEMBL 등에서 IC50 데이터 수집
- 이질적인 단백질 중 MAP3K5 단백질 서열과 PSI-BLAST 기반 유사도 높은 단백질 선별
- BLAST 점수는 z-score 변환 후 sigmoid를 적용하여 입력으로 사용
→ 241,586개 화합물과 389개 단백질 간 381,152개 IC50 데이터 수집


화합물 표현법



- 그래프 기반 KPGT
 - hypergraph로 화합물 표현
 - Graph Transformer로 사전학습
- SMILES 기반 ChemBERTa
 - SMILES를 토큰화, RoBERTa 모델에 입력
 - 랜덤으로 마스킹된 입력으로 화합물 특성을 예측하는 방식으로 사전학습
- SELFIES 기반 SELFIES-TED
 - 항상 유효한 분자를 표현하도록 설계
 - 80억 개 ZINC 데이터셋으로 BART 모델 기반 사전학습


Uncertainty-aware BLAST-weighted Multi-Representation Ensemble Model

모델 구축



- KPGT, ChemBERTa, SELFIES-TED 등 세가지 화합물 표현법을 활용하여 서로 다른 모델을 학습, 각 모델에서 pIC50과 불확실성을 예측.
- 예측한 불확실성과 BLAST 유사도를 고려해서 모델의 가중치를 예측
- Weighted sum으로 최종 예측 값 도출


손실 함수



$$L = \underbrace{\frac{1}{N} \sum_{i=1}^N (1 + \beta z_{b,i}) (y_i - \hat{y}_i)^2}_{\text{Confidence-Weighted MSE}} + \underbrace{\alpha \cdot \frac{1}{N} \sum_{i=1}^N \left(\log(\text{unc}_i) + \frac{(y_i - \hat{y}_i)^2}{2 \text{unc}_i} \right)}_{\text{Uncertainty Loss}}$$

- Confidence-weighted MSE
 - BLAST 점수 기반 가중치를 부여한 MSE 계산
- Uncertainty Loss
 - Negative Log-likelihood 기반
 - 실제 오차에 맞춰 불확실성을 조정하고 과대 추정을 억제
- 최종 손실함수
 - 두 손실을 $\alpha = 0.1$ 로 선형 결합하여 사용

기여도 평가



- 고정된 test set으로 각 composition의 기여도 평가
- 단일 임베딩 기여도 : KPGT > SELFIES-TED > ChemBERTa

학습 전략

- 활성 부위 보존성이 높은 kinase의 특성을 고려하여 BLAST 기반 similarity로 타겟 단백질을 선별해 학습에 활용함
- ChemBERTa, KPGT, SELFIES-TED 등 다양한 molecular representation을 통합한 ensemble model을 구축함
- 모델이 예측한 불확실성을 BLAST 점수로 보정하여 더욱 안정적이고 정확한 예측을 수행함
- 고정된 test set으로 3가지 표현법의 기여도를 평가, Top 3 모델을 선별했으며 Dacon dataset 검증에서 모든 representation을 활용한 모델이 최고 성능 (private score = 0.648) 을 기록함
- 단백질 서열의 임베딩을 활용하여 cross-attention으로 학습한 모델보다 BLAST 기반 단백질 점수화 방식이 더 우수한 성능을 보임
- 본 접근법은 다른 kinase에도 적용 가능하며, IC50 예측뿐만 아니라 다양한 DTI regression 모델에도 확장 가능함

※ 참고문헌

- Li, H., Zhang, R., Min, Y., Ma, D., Zhao, D., & Zeng, J. (2023). A knowledge-guided pre-training framework for improving molecular representation learning. *Nature Communications*
- Chithrananda, S., Grand, G., & Ramsundar, B. (2020). ChemBERTa: Large-Scale Self-Supervised Pretraining for Molecular Property Prediction. *arXiv preprint*
- Krenn, M., Hise, F., Nigam, A., Friederich, P., & Aspuru-Guzik, A. (2020). Self-Referencing Embedded Strings (SELFIES): A 100% robust molecular string representation. *arXiv preprint*
- Priyadarsini, I., Takeda, S., Hamada, L., Brazil, E. V., Soares, E., & Shinohara, H. (2025). SELFIES-TED: A Robust Transformer Model for Molecular Representation using SELFIES. *arXiv preprint*